

- **Entrega Semana 02: Clasifica datos y las V del Big Data**

Asignatura: Ciencia de Datos — Periodo 2026-B

Institución: Corporación Universitaria del Huila (CORHUILA)

Programa: Ingeniería Industrial / Mecatrónica

Unidad / Corte: Unidad 1 / Corte 1 — Semana 02

1. Clasificación Tipológica y Arquitectura de Ingesta de Datos

En el marco del proyecto de mantenimiento predictivo para activos electromecánicos críticos (motores de inducción trifásicos y reductores industriales), la integración heterogénea de fuentes exige categorizar los flujos de datos según su nivel de estructuración y definir su motor de almacenamiento óptimo (*Davenport & Bean, 2019*):

Fuente de Datos	Clasificación	Formato / Esquema	Motor de Almacenamiento / Pipeline	Descripción Técnica de Contenido
1. Histórico de Órdenes de Trabajo (CMMS)	Estructurado	Tablas SQL relacionales	PostgreSQL / Enterprise RDBMS	Registros tabulares estrictos: ID_Activo, Fecha_Intervencion, MTBF, MTTR, Costo_Reparacion,Codigo_Falla y repuestos utilizados.
2. Historiador de Proceso SCADA	Estructurado	Series de tiempo	InfluxDB / TimescaleDB	Muestreo tabular indexado por tiempo (<i>timestamp</i>): variables

Fuente de Datos	Clasificación	Formato / Esquema	Motor de Almacenamiento / Pipeline	Descripción Técnica de Contenido
				operativas continuas como velocidad angular (RPM), carga (%), corriente RMS (A) y potencia activa (kW).
3. Telemetría IoT (Acelerometría / Termometría)	Semi-estructurado	Payloads JSON / BSON	Broker MQTT + Apache Kafka	Estructuras clave-valor jerárquicas con metadatos del sensor (node_id, sampling_rate) y arreglos numéricos con formas de onda de vibración triaxial (Ax, Ay, Az).
4. Logs de Eventos del Sistema de Control (PLC)	Semi-estructurado	Archivos de texto .log / XML / Syslog	Elasticsearch / Logstash (ELK Stack)	Trazas cronológicas no tabulares delimitadas por marcas de texto: excepciones de <i>firmware</i> , interrupciones de bus de campo (PROFINET/

Fuente de Datos	Clasificación	Formato / Esquema	Motor de Almacenamiento / Pipeline	Descripción Técnica de Contenido
				Modbus), alarmas de sobrecorriente y caídas de tensión.
5. Informes de Inspección y Bitácoras	No estructurado	Texto libre / PDF / Word	Amazon S3 / HDFS (Data Lake)	Documentación cualitativa redactada por técnicos sobre observaciones visuales, análisis de causa raíz, ruidos anómalos detectados e historial de lubricación.
6. Termografía Infrarroja	No estructurado	Imágenes matriciales (TIFF / JPEG térmico)	Data Lake (S3) + Metadatos NoSQL (MongoDB)	Matrices bidimensionales de radiación infrarroja que representan perfiles de temperatura punto a punto en carcasas de motores, rodamientos y tableros eléctricos.

Fuente de Datos	Clasificación	Formato / Esquema	Motor de Almacenamiento / Pipeline	Descripción Técnica de Contenido
7. Grabaciones de Audio Ultrasónico/Acústico	No estructurado	Archivos de audio digital .wav / .flac	MinIO / HDFS + Procesamiento en PySpark	Señales de presión sonora de alta frecuencia (20 kHz - 100 kHz) para la identificación temprana de cavitación en bombas, fricción interna y micro-fisuras en pistas de rodamientos.

2. Análisis Profundo de las 5 V del Big Data en la Planta

El volumen y dinamismo del mantenimiento predictivo exige una infraestructura analítica balanceada bajo el paradigma de las 5 V (*Gartner, 2021; Zikopoulos et al., 2012*):

1. Velocidad (Crítica Alta)

- **Reto Técnico:** Los sensores piezoeléctricos toman datos a frecuencias de hasta 10 kHz a 20 kHz por canal para capturar fenómenos transitorios y armónicos de alta frecuencia.
- **Solución:** Procesamiento en flujo (*Stream Processing*) en la capa *Edge* y *Cloud* utilizando Apache Kafka como bus de eventos y Apache Spark Streaming/Flink para calcular indicadores en tiempo real (p. ej., valor RMS, Factor de Cresta y FFT instantánea). Si se detecta un patrón crítico, el sistema debe alertar en menos de 100 milisegundos para evitar fallas catastróficas.

2. Variedad (Crítica Alta)

- **Reto Técnico:** Coexistencia de tablas SQL relacionales, documentos NoSQL, gráficos espectrales, registros de texto y binarios de audio/imagen.
- **Solución:** Implementación de una arquitectura **Data Lakehouse** (como Delta Lake o Apache Iceberg), la cual permite almacenar datos no estructurados en bruto y, al

mismo tiempo, aplicar esquemas de lectura (*Schema-on-Read*) y consultas SQL de alto rendimiento sobre datos estructurados y semi-estructurados.

3. Veracidad (Crítica Alta)

- **Reto Técnico:** Un dato erróneo generado por interferencias electromagnéticas (EMI) o descalibración puede desencadenar una parada de planta no planificada (falso positivo), generando pérdidas millonarias, o pasar por alto un fallo real (falso negativo).
- **Solución:** Capas automatizadas de limpieza, validación de reglas de negocio, filtros de Kalman/Butterworth para remoción de ruido y protocolos de linaje de datos (*Data Lineage*).

4. Volumen (Moderada / Alta)

- **Reto Técnico:** Un solo motor con 4 sensores de vibración transmitiendo a 10 kHz genera un estimado de **1.5 GB a 3 GB de datos crudos por día**. En una planta con 50 motores, el volumen anual supera fácilmente los 30 a 50 Terabytes.
- **Solución:** Procesamiento previo en dispositivos *Edge* (reducción de datos por extracción de características antes de transmisión), compresión columnar en formatos eficientes (Parquet/ORC) y políticas de almacenamiento multinivel (*Hot/Cold Storage*).


5. Valor (Objetivo Final)

- **Impacto Operativo:** Convertir datos crudos en variables de salud del activo (Índice de Salud de la Máquina) e estimación de la **Vida Útil Restante (RUL - *Remaining Useful Life*)**.
- **Impacto Financiero:** Reducción de hasta un 30% en costos de mantenimiento, erradicación de paradas no programadas en líneas críticas de producción y optimización en la adquisición de repuestos de alto valor.

3. Reto Concreto de Veracidad (Calidad de Datos) y Protocolo de Detección

- **Problema Identificado:** *Ruido por Interferencia Electromagnética (EMI) y Deriva de Cero en Sensores Piezoeléctricos*

En entornos industriales pesados, el arranque de motores de gran potencia y la conmutación de frecuencia en los variadores de velocidad (VFD) introducen ruido transitorio de alta amplitud en las líneas de transmisión de los sensores. Además, las variaciones térmicas drásticas en la carcasa del motor provocan "deriva de cero" (*zero-drift*) en los acelerómetros, sesgando la señal base.



- **Protocolo de Detección y Mitigación en 3 Niveles:**

1. **Validación por Límites Físicos (*Domain Boundaries Check*):**

- **Nivel Edge (Firmware / Node-RED):** Filtrado de lecturas que superen la aceleración máxima físicamente posible del equipo (ej. > 50g) o lecturas de temperatura fuera del rango razonable de operación (-20°C a 180°C). Se marcan con bandera de error `FLAG_INVALID_RANGE`.

2. **Detección Estadística de Anomalías (*Robust Z-Score e IQR*):**

- **Nivel Stream:** Cálculo en ventanas deslizantes temporales (ej. N=100 muestras) del Rango Intercuartílico ($IQR = Q_3 - Q_1$). Toda lectura x_i tal que:

$$x_i > Q_3 + 3 \times IQR \quad \text{o} \quad x_i < Q_1 - 3 \times IQR$$

se identifica como un pico espurio generado por EMI y se reemplaza automáticamente mediante interpolación lineal o la mediana de la ventana.

3. **Prueba de Continuidad y Autocorrelación Temporal (ρ_1):**

- **Nivel Batch / Analytics:** Monitoreo continuo del coeficiente de autocorrelación con desfase 1 (ρ_1). Si ρ_1 cae drásticamente a valores cercanos a cero mientras la máquina está operando, el algoritmo identifica una señal no correlacionada (ruido blanco estático), lo que indica desacoplamiento físico del sensor, rotura del cable de señal o falla en la comunicación MQTT.

4. Referencias Bibliográficas Verificadas (Con DOI / ISBN)

- **CORHUILA.** (2026). *Guía de Actividad Práctica: Ciencia de Datos Semana 2. Clasifica datos y las V del Big Data*. Corporación Universitaria del Huila, Programa de Ingeniería Industrial / Mecatrónica.
- **Davenport, T. H., & Bean, R.** (2019). *Big Data and AI Executive Survey 2019: Executive Summary of Findings*. NewVantage Partners LLC.
<https://www.newvantage.com/survey2019>
- **Gartner.** (2021). *Gartner Glossary: Big Data*. Gartner Research.
<https://www.gartner.com/en/information-technology/glossary/big-data>
- **Hashemian, H. M.** (2011). State of the art in online monitoring to extend operational life of nuclear power plant equipment. *Nuclear Engineering and Design*, 241(1), 41-50. <https://doi.org/10.1016/j.nucengdes.2010.10.012>
- **Mobley, R. K.** (2002). *An Introduction to Predictive Maintenance* (2nd ed.). Butterworth-Heinemann (Elsevier). ISBN: 978-0750675314.
- **Zikopoulos, P., Eaton, C., deRoos, D., Deutsch, T., & Lapis, G.** (2012). *Understanding Big Data: Analytics for Enterprise Class Hadoop and Streaming Data*. McGraw-Hill Osborne Media. ISBN: 978-0071790543