

Entrega semana 3: Diseño de Arquitectura de Datos para Mantenimiento Predictivo Industrial

Asignatura: Ciencia de Datos — Periodo 2026-B

Institución: Corporación Universitaria del Huila (CORHUILA)

Programa: Ingeniería Industrial / Mecatrónica

Unidad / Corte: Unidad 1 / Corte 1 — Semana 03

Modalidad: Formativa (Individual / Parejas)

1. Diagrama End-to-End de la Arquitectura de Datos

El diseño arquitectónico adopta un enfoque híbrido tipo **Data Lakehouse** impulsado por el paradigma **Lambda/Kappa Architecture**, permitiendo la ingesta, almacenamiento, procesamiento y explotación analítica de fuentes tanto en tiempo real como en procesamiento por lotes (*batch*): Fue realizado en un archivo aparte

Descripción del Flujo

- **1. Fuentes:** Orígenes de información estructurada (bases de datos relacionales), semi-estructurada (APIs, logs) o archivos crudos.
- **2. Ingesta:** Mecanismos de extracción y carga, divididos en **Batch** (procesamiento por lotes programados) o **Streaming** (captura de datos en tiempo real).
- **3. Almacenamiento:** Repositorios principales. El *Data Lake* guarda la información cruda o semi-procesada, mientras que el *Data Warehouse* la organiza de forma optimizada y analítica.
- **4. Procesamiento:** Capa donde se limpian, cruzan, enriquecen y transforman los datos (*Spark*, *dbt*, *SQL*) para dejarlos listos para consumo.
- **5. Análisis / BI:** Capa final orientada a negocio e inteligencia artificial (visualización de reportes, analítica avanzada, modelos predictivos).

2. Justificación Técnica de Decisiones Arquitectónicas

A. Almacenamiento: Data Lakehouse (Data Lake + Data Warehouse)

Se selecciona una arquitectura integrada de **Data Lakehouse** (combinando las capacidades de almacenamiento en bruto masivo de un Data Lake con el rendimiento y consistencia transaccional ACID de un Data Warehouse):

- **Uso del Data Lake (Capa Bronze / Silver):** Almacena volúmenes masivos de datos no estructurados y semi-estructurados (imágenes termográficas, archivos de

audio .wav y cargas útiles JSON de IoT) a muy bajo costo utilizando formatos abiertos optimizados como Apache Parquet o Delta Lake.

- **Uso del Data Warehouse (Capa Gold / Serving):** Almacena datos estructurados, modelados en esquemas de estrella (*Star Schema*) con alta velocidad de consulta SQL para la generación de reportes gerenciales, indicadores clave de rendimiento (KPIs como MTBF y MTTR) y paneles interactivos en Power BI.

B. Estrategia de Ingesta: Modelo Híbrido (Batch + Streaming)

- **Flujo en Tiempo Real (Streaming):** Requerido de forma crítica para las señales de vibración triaxial y corriente eléctrica RMS. Un retraso en la detección de resonancia o falla de rodamiento puede destruir el motor en cuestión de segundos. El streaming permite evaluar ventanas de tiempo de alta frecuencia y emitir paradas de emergencia en milisegundos.
- **Flujo por Lotes (Batch):** Utilizado para sincronizar de manera diaria o por turnos los registros de mantenimiento del CMMS, bitácoras manuales de inspección e imágenes termográficas. Estos datos no cambian segundo a segundo y su procesamiento en bloque optimiza el uso de recursos computacionales.

3. Selección y Justificación de Herramientas por Etapa

Etapa PDF	Herramienta Candidata	Justificación Técnica de Selección PDF
Ingesta	Apache Kafka	Plataforma distribuida de transmisión de eventos de alta disponibilidad, capaz de ingerir millones de mensajes por segundo desde miles de nodos IoT con latencia inferior a 10 milisegundos.
Almacenamiento	Delta Lake (sobre AWS S3)	Proporciona soporte para transacciones ACID, control de versiones de datos (<i>time travel</i>) y escalabilidad masiva sobre almacenamiento de objetos de bajo costo.
Procesamiento	Apache Spark (Core & Structured Streaming)	Motor de procesamiento unificado distribuido en memoria que permite ejecutar análisis espectral (FFT) en flujo continuo y entrenar modelos predictivos de Vida Útil Restante (RUL) en <i>batch</i> .

Etapas PDF	Herramienta Candidata	Justificación Técnica de Selección PDF
Análisis & BI	Microsoft Power BI + Grafana	Power BI para la capa gerencial y analítica de negocio (costos, disponibilidad de flota) y Grafana para el monitoreo operacional de series temporales con alertas en tiempo real.

4. Referencias Bibliográficas Verificadas (Con DOI / ISBN)

- **Armbrust, M., Ghodsi, A., Xin, R., & Zaharia, M.** (2021). Lakehouse: A new class of open platforms that seamlessly combine data warehouse and data lake capabilities. *Proceedings of the 11th Conference on Innovative Data Systems Research (CIDR)*, 1-6. https://cidrdb.org/cidr2021/papers/cidr2021_paper17.pdf
- **CORHUILA.** (2026). *Guía de Actividad Práctica: Ciencia de Datos Semana 3. Diseña una arquitectura de datos.* Corporación Universitaria del Huila, Programa de Ingeniería Industrial / Mecatrónica.
- **Kleppmann, M.** (2017). *Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems.* O'Reilly Media. ISBN: 978-1449373320.
- **Kreps, J., Narkhede, N., & Rao, J.** (2011). Kafka: A distributed messaging system for log processing. *Proceedings of the NetDB*, 1-7. <https://doi.org/10.1145/2034052.2034059>
- **Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., ... & Stoica, I.** (2016). Apache Spark: A unified engine for big data processing. *Communications of the ACM*, 59(11), 56-65. <https://doi.org/10.1145/2999252>