

- **Entrega semana 4: Tipos de analítica y ética**

Asignatura: Ciencia de Datos — Periodo 2026-B
Institución: Corporación Universitaria del Huila (CORHUILA)
Programa: Ingeniería Industrial / Mecatrónica
Unidad / Corte: Unidad 1 / Corte 1 — Semana 04

1. Clasificación de Preguntas por Tipo de Analítica

De acuerdo con las especificaciones de la Guía de Actividad Práctica de CORHUILA (2026), se abordan las 4 preguntas sobre un caso del sector industrial (Gestión de Inventarios y Mantenimiento Predictivo):

- **Analítica Descriptiva:** *¿Cuál fue el promedio mensual de fallas mecánicas y el tiempo de inactividad de las máquinas en la planta productiva durante el último año?*
 - **Propósito:** Resumir y presentar datos históricos para entender lo que ocurrió en el pasado (Gartner, 2020).
- **Analítica Diagnóstica:** *¿Por qué se produjo un incremento del 25% en el desgaste de los rodamientos de la Línea A durante el segundo trimestre?*
 - **Propósito:** Investigar las causas raíz de los eventos identificados mediante técnicas de minería de datos y análisis de correlación (Davenport & Harris, 2007).
- **Analítica Predictiva:** *¿Cuál es la probabilidad de que la prensa hidráulica principal falle en las próximas 100 horas de operación continua según sus patrones de vibración y temperatura?*
 - **Propósito:** Utilizar modelos estadísticos y de aprendizaje automático para anticipar eventos futuros (Hyndman & Athanasopoulos, 2021).
- **Analítica Prescriptiva:** *¿Cómo debemos ajustar el programa de mantenimiento preventivo y la calibración de carga de las máquinas para minimizar los costos operativos un 15% manteniendo el riesgo de falla por debajo del 2%?*
 - **Propósito:** Recomendar acciones concretas y evaluar sus consecuencias mediante técnicas de optimización y simulación (Lustig et al., 2010).

2. Clasificación y Justificación de Machine Learning (Predictiva/Prescriptiva)

Atendiendo al segundo requerimiento del enunciado de la guía, se especifica el tipo de aprendizaje de Machine Learning a utilizar:

Se utilizará un enfoque de **Machine Learning Supervisado**.

Justificación:

1. **Disponibilidad de Datos Etiquetados:** En el entorno industrial se cuenta con registros históricos que contienen las lecturas de los sensores (temperatura, vibración, presión) asociadas a una etiqueta o resultado explícito ("*Falla*" / "*No Falla*" o el tiempo hasta la falla - *Time to Failure*).
2. **Naturaleza del Problema:**
 - **Para la Analítica Predictiva:** Se aborda como un problema de **Clasificación** (predecir el estado de falla) o **Regresión** (estimar el tiempo de vida útil restante o *RUL*).
 - **Para la Analítica Prescriptiva:** Las predicciones del modelo supervisado sirven como entrada para los algoritmos de optimización matemática, permitiendo seleccionar la mejor decisión operativa bajo restricciones de costo y riesgo.

Nota: Aunque el aprendizaje **No Supervisado** (como la detección de anomalías sin etiquetar) es útil en etapas exploratorias iniciales, el enfoque supervisado (*p. ej.*, *Random Forest*, *XGBoost*) ofrece la precisión requerida para tomar acciones correctivas directas en la planta (Goodfellow et al., 2016).

3. Riesgos Éticos, Sesgos y Estrategias de Mitigación

Dando cumplimiento al punto de riesgos éticos y sesgos solicitado en la guía práctica:

A. Riesgo Ético y Sesgo Identificado

- **Sesgo de Selección / Datos Históricos Incompletos (*Historical Bias*):** Ocurre si los datos de entrenamiento proceden únicamente de períodos con baja carga operativa. El modelo no sabrá reaccionar adecuadamente ante escenarios de alta demanda.
- **Impacto Ético/Laboral:** Un falso negativo (predecir operabilidad normal cuando existe una falla inminente) genera un riesgo directo para la seguridad física de los operarios de la planta.

B. Estrategia de Mitigación

1. **Auditoría de Datos:** Realizar un Análisis Exploratorio de Datos (EDA) para garantizar representatividad de todas las condiciones de trabajo (distintas cargas, turnos, estaciones del año y variaciones de insumos).
2. **Métricas de Equidad e Interpretabilidad (*Fairness & Explainability*):** Implementar herramientas de explicabilidad (*p. ej.*, *SHAP* o *LIME*) para auditar las variables explicativas y descartar correlaciones espurias o sesgadas.

3. **Mecanismo *Human-in-the-loop*:** Las recomendaciones prescriptivas de alto impacto deben ser validadas por un ingeniero responsable antes de ejecutar paradas críticas de producción (Barocas et al., 2019).

Referencias Bibliográficas

- Barocas, S., Hardt, M., & Narayanan, A. (2019). *Fairness and Machine Learning: Limitations and Opportunities*. MIT Press.
- Corporación Universitaria del Huila (CORHUILA). (2026). *Guía de Actividad Práctica: Ciencia de Datos Semana 4 - Tipos de analítica y ética* (Programa de Ingeniería Industrial, Periodo 2026-B). Neiva, Colombia.
- Davenport, T. H., & Harris, J. G. (2007). *Competing on Analytics: The New Science of Winning*. Harvard Business School Press.
- Gartner. (2020). *Gartner Glossary: Analytics continuum (Descriptive, Diagnostic, Predictive, Prescriptive)*. Gartner Research.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: principles and practice* (3rd ed.). OTexts.
- Lustig, I., Dietrich, B., Donnelly, C., & Schreiber, G. (2010). The Analytics Journey: How to move from Descriptive to Prescriptive Analytics. *Analytics Magazine*, 2010(6), 22-29.